

城市出租车供需错配与空驶再平衡优化

基于 NYC TLC Yellow Taxi 分区小时流数据的预测—优化模型

第一组

23 信科陈龙 22 光华王溪斌 23 元培汤平之

2026 年 5 月 21 日

摘要

本文以 NYC TLC Yellow Taxi 公开行程数据为基础，构造分区 $\times$ 小时的供需面板，拟合下一小时区域乘车需求的预测模型，并把预测结果作为输入求解空车再平衡的线性规划。对比三种调度策略——不调度、最近邻贪心和 LP 全局优化，并通过蒙特卡洛模拟评估 LP 方案在需求扰动下的稳健性。原始 Parquet 的下载与清洗在 Python 中完成，预测、LP、基线对比、蒙特卡洛、敏感性分析等全部数值计算在北太天元中完成，Python 仅负责把北太天元导出的 CSV 渲染为最终图像。

核心结果：当未满足惩罚 λ 取经济上可辩护的下界 $\lambda = 20$ 时，在 24 个测试小时上 LP 与贪心达到完全相同的真实未满足需求水平，但 LP 把空驶距离成本平均降低 2–5 倍（多个小时下降幅超过 3 倍），且该优势在蒙特卡洛 200 次需求扰动场景下保持稳定。

1 背景与问题

城市出租车系统在时间和空间上存在显著的供需错配：工作日晚高峰曼哈顿核心区往往车少人多，机场和外围区域则相反。空驶再平衡 (empty-vehicle rebalancing) 是平台或调度中心的一种主动干预手段——在不抢占已被乘客占用的车辆的前提下，把可能空驶的车辆引导到预测需求缺口最大的区域，从而降低未满足需求并控制空驶距离。平台实时车辆库存数据并不公开，本文改用一个保守可解释的供给代理：当前小时各区域的 dropoff 数 $Q_{i,t}$ 。研究问题为：

给定 $(Q_{i,t})$ 与历史 *pickup* 时序，预测下一小时各区域需求 $\hat{P}_{i,t+1}$ ，求解使空驶距离与未满足需求加权和最小的调度方案 $\{x_{ij,t}\}$ ，比较其相对于贪心和不调度基线的改善幅度，并在需求随机扰动下评估稳健性。

2 数据与特征

数据源为 NYC Taxi & Limousine Commission 公开的 Yellow Taxi Trip Records，范围 2024-01 至 2024-03（约 955 万行原始行程），按小时聚合，按训练期 pickup 量选取 top 50 个 taxi zone。最终面板共 109,250 行（50 zones $\times$ 2,185 hours） $\times$ 19 列特征。

清洗规则 pickup/dropoff 时间或 zone id 缺失、trip_distance $\notin (0, 100]$ 、duration $\notin [1, 180]$ 分钟、fare_amount ≤ 0 或 total_amount ≤ 0 、pickup 时间不在目标月份的行程一律删除。三个月份的整体存活率分别为 96.4%、96.1% 和 95.7%（详见附录 B）。

特征 (19 列) 2 列 ID (zone_id、hour_index)、2 列实测计数、4 列 1/2 小时滞后、3 列 6/24 小时滚动均值、2 列同小时前 1 日/前 1 周 pickup、5 列时间分类与编码、1 列 split_id。详细字段表见附录 A。train/val/test 按时间切 70%/15%/15%，不做随机切分以避免时间泄漏。

数据完整性 Python 端 06_validate.py 对全部 7 个 processed 文件运行 11 项独立断言（列对齐、按 (zone, hour_index) 升序、每个 zone 的 hour_index 连续无缺、cost matrix 对角为 0 且非对角正而有限、test_hours 全部落在 test 切分内、split 占比误差 $\leq 5\%$ 、无 NaN、计数非负、lag/rolling 已 fill、清洗存活率 $\in (0.5, 1.0)$ ）。TLC 编号 264 (Unknown) 与 265 (Outside of NYC) 这两个 catch-all 占位 zone 在选 top-50 时被显式排除——这是项目深度审计阶段才发现的数据陷阱。

3 数学模型

样本单位 (i, t) : 第 i 个 zone，第 t 个小时。定义 $P_{i,t}$ = pickup 数， $Q_{i,t}$ = dropoff 数， $B_{i,t} = Q_{i,t} - P_{i,t}$ 。

下一小时需求预测 两个模型并行训练，下游 LP 输入采用两者中测试 MAE 较低者：历史均值基线 $\hat{P}_{i,t+1} = \bar{P}|_{\text{zone}=i, \text{wd}=\text{wd}(t+1), \text{hod}=\text{hod}(t+1)}$ ；Ridge 回归 $\hat{\beta} = (X^\top X + \alpha I)^{-1} X^\top y$ ， $\hat{P}_{i,t+1} = \max(z_{i,t}^\top \hat{\beta}, 0)$ 。本数据集上前者 MAE = 16.83，后者 18.46，故选历史均值。

需求缺口、剩余供给与成本矩阵 $D_{j,t+1} = \max(\hat{P}_{j,t+1} - Q_{j,t}, 0)$ ， $S_{i,t} = \max(Q_{i,t} - \hat{P}_{i,t+1}, 0)$ ； c_{ij} 为训练期 $i \rightarrow j$ 行程的 trip_distance 中位数（缺失依次用同 borough 中位数、全局中位数 $\times 1.5$ 兜底），对角线为 0。top-50 之间 OD 对覆盖率 100%，最终 $c_{ij} \in [0.5, 22.75]$ mi。

LP 再平衡 $x_{ij,t} \geq 0$ ：从 i 调往 j 的空车强度； $u_{j,t} \geq 0$ ： j 仍未满足的预测缺口。

$$\begin{aligned} & \min_{x,u} \sum_{i,j} c_{ij} x_{ij,t} + \lambda \sum_j u_{j,t} \\ \text{s.t.} \quad & \sum_j x_{ij,t} \leq S_{i,t} \quad \forall i, \quad \sum_i x_{ij,t} + u_{j,t} \geq D_{j,t+1} \quad \forall j, \quad x_{ij,t} \geq 0, \quad u_{j,t} \geq 0. \end{aligned}$$

连续 relaxation， x_{ij} 解释为期望调度强度。LP column-major 构造见附录 E。

λ 的经济学依据 λ 单位为英里，与 c_{ij} 同量纲，含义为漏掉 1 个 trip 等价于多少英里空驶。基于 NYC TLC 2024 Yellow Taxi 标准费率与司机单位空驶成本：

视角	λ 推导	值 (mi)
司机	单趟净收入 (\$12) / 空驶单位成本 (\$0.40/mi)	≈ 30
社会	(净收入 + 客户机会成本 \$5) / 单位成本	≈ 42
平台	折扣率回报法	$\approx 20\text{--}25$

故经济上可辩护的区间为 $\lambda \in [20, 42]$ 。我们以 $\lambda = 20$ （保守下界）作为默认值，并在附录 I 给出 $\lambda \in \{1, 2, 5, 10, 15, 20, 30, 50, 100, 200\}$ 的完整 sensitivity sweep——在 $\lambda \in [20, 200]$ 区间内 LP 已饱和到固定 unmet/cost，说明对参数选择不敏感。

评价指标 预测：MAE、RMSE、sMAPE；调度（用真实下一小时 $P_{j,t+1}^{\text{true}}$ 评估）： $\tilde{Q}_{j,t} = Q_{j,t} - \sum_k x_{jk,t} + \sum_i x_{ij,t}$, $u_{j,t}^{\text{real}} = \max(P_{j,t+1}^{\text{true}} - \tilde{Q}_{j,t}, 0)$, $U_t = \sum_j u_{j,t}^{\text{real}}$ 。服务率 $1 - U_t / \sum_j P_{j,t+1}^{\text{true}}$ ，单位改善成本 $C_t^{\text{method}} / \max(U_t^{\text{base}} - U_t^{\text{method}}, \varepsilon)$ 。

4 算法实现

Python 仅做数据预处理（下载 Parquet、清洗、面板与特征、成本矩阵、11 项数据断言；脚本 01_download_tlc.py-06_validate.py）与最终图像 / PPTX 拼装（07_render_figures.py 调 matplotlib 渲染 6 张 PNG，08_build_pptx.py 把 Beamer 渲染出的幻灯片 PNG 与中文讲稿自动同步进 ppt/lecture.pptx 的讲者备注）。

北太天元 承担全部数学：run_all.m 一键执行读取 $\rightarrow$ split 校验 $\rightarrow$ 拟合两个预测器 $\rightarrow$ 24 测试小时下 linprog 解 LP 同步 greedy / no-rebalance $\rightarrow$ λ sensitivity 20 个值 $\times$ 24 小时 $\rightarrow$ Monte Carlo 200 Poisson 扰动 $\rightarrow$ 5 张图源 CSV。tests/ 中 3 个手工可验证小测试（ 2×2 LP、无缺口、无剩余供给）在 Baltamatica 2025 社区版上全部通过。社区版兼容性 6 项发现见附录 K。

5 实验结果

预测精度（test 集）

model	split	MAE	RMSE	sMAPE
historical_mean	test	16.861263	28.917495	0.311524
ridge	test	18.462198	29.787078	0.405290

历史均值显著优于 Ridge——前者天然按 zone $\times$ wd $\times$ hod 分桶，后者 15 维全局特征无法刻画 zone 间几十倍量级的水平差异。

核心调度对比 图 1 展示 24 测试小时上三种策略的真实未满足需求与空驶成本。**关键结论**：LP 与贪心的真实 unmet 几乎重合（差异 $< 1\%$ ），但 LP 的空驶成本平均低 2–5 倍。典型例子：hour 14 中 greedy 烧 5033 mi 空驶而 LP 只需 1540 mi（**3.3 倍**），hour 18 是 3197 vs 707（**4.5 倍**），hour 17 是 921 vs 429（**2.1 倍**）。这是 LP 全局最优相对贪心 逐缺口贪婪的本质差异。




图 1: 24 个测试小时上三种调度策略的真实未满足需求（上）与空驶成本（下）对比。LP 与 greedy 在 unmet 上几乎重合，但 LP 的 cost 显著更低。

Monte Carlo 稳健性 固定 LP 调度方案 X^* ，对真实需求采 200 次 Poisson 扰动后评估：LP 与 greedy 的 mean unmet 均为 19.7，q05 service rate 均为 0.9647，显著优于 no-rebalance (mean unmet 259.9)。LP 在需求噪声下不退化（见附录 N 图 3）。

λ 敏感性 $\lambda \leq 5$ 时 LP 几乎不调度 (unmet ≈ 310)； $\lambda \in [10, 20]$ 是 cost-quality 拐点； $\lambda \geq 20$ 已饱和到 unmet = 77.7、service = 0.949。经济上可辩护的全部区间 $[20, 42]$ 都落在饱和带，说明对参数不敏感（详见附录 I）。

Top LP 调度流 前 5 条流量最大的 OD 边都是 Manhattan 住宅区 $\rightarrow$ 机场 (Murray Hill $\rightarrow$ JFK 778 单、Yorkville East $\rightarrow$ LaGuardia 553 单等)，后续 10 条是 Manhattan 内部住宅区 $\rightarrow$ 商务区。说明 LP 学到的调度方案符合城市出行结构，具有可解释性（见附录 N 图 4）。

6 结论与局限

LP 全局优化的空车再平衡方案在 24 个代表性测试小时上一致达到与贪心相同的未满足需求水平，但空驶成本平均低 2–5 倍；该优势在 Monte Carlo 200 次扰动下稳定。 λ 的经济学下界 20 与饱和上界 200 之间形成宽阔的稳态区间，参数选择鲁棒。

局限： (1) dropoff 流仅为供给代理，不等同于平台实时空车库存；(2) 未引入天气、道路拥堵、大型活动等外生数据；(3) LP 为连续 relaxation， x_{ij} 是期望强度，部署需整数化；(4) 成本矩阵基于历史中位数，未考虑实时路况；(5) 假设调度瞬时执行，未模拟驾驶时延；(6) Ridge 缺 zone embedding，弱于强基线历史均值，后续可加入 zone 固定效应改进。

A 数据字段说明

面板共 19 列:

- zone_id, hour_index (Unix 小时, int64)
- pickup_count, dropoff_count
- lag_pickup_1h, lag_pickup_2h, lag_dropoff_1h, lag_dropoff_2h
- rolling_pickup_mean_6h, rolling_pickup_mean_24h, rolling_dropoff_mean_6h
- same_hour_prev_day_pickup, same_hour_prev_week_pickup
- hour_of_day, weekday, is_weekend, hour_sin, hour_cos
- split_id (0=train / 1=val / 2=test)

B 清洗规则与样本数变化

完整步骤逐行记录在 `results/tables/cleaning_summary.csv`, 按月份和清洗步骤汇报剩余行数。三月份原始样本 2,964,624 / 3,007,526 / 3,582,628, 最终干净样本累计 9,177,579 (综合存活率 96.0%)。

C 特征工程表

所有 lag、rolling、same_hour 特征均通过 pandas 的 `groupby('zone_id').shift(N)` 或对应的 `.rolling(N).mean()` 构造; 前 24 小时或前 7 日窗口不足时 fill 0 而非 NaN, 保证零 NaN 进入北太天元。

D 数学模型完整公式

评估阶段使用 真实 P_{t+1}^{true} 而非 $\hat{P}_{t+1}$; 服务率 $\text{srv}_t = 1 - U_t / \max(\sum_j P_{j,t+1}^{\text{true}}, \varepsilon)$; 单位改善成本 $\text{unit cost} = C_t^{\text{method}} / \max(U_t^{\text{base}} - U_t^{\text{method}}, \varepsilon)$ 。

E LP 矩阵构造细节

变量按 column-major 排列:

$$\mathbf{z} = [\underbrace{x_{11}, x_{21}, \dots, x_{K1}}_{\text{col 1 of } X}, \underbrace{x_{12}, \dots, x_{K2}}_{\text{col 2}}, \dots, \underbrace{x_{1K}, \dots, x_{KK}}_{\text{col K}}, u_1, \dots, u_K]^\top$$

故 `reshape(z(1:K*K), K, K)` 恰好恢复 X , 与 `C(:)` 顺序对齐。 A 矩阵尺寸 $2K \times (K^2 + K)$, 上半部分 K 行供给约束, 下半部分 K 行需求约束 (取负)。

F 北太天元核心代码索引

code/beita/ 共 12 个 .m 文件 + 4 个测试, 全部在 Baltamatica 2025 社区版兼容:

- run_all.m: 一键 12 步主流水线
- config_project.m: 全局参数 (α , λ , MC 次数, 种子)

- `load_processed_data.m`: `fopen+fread+sscanf` 快速 CSV 读
- `predict_historical_mean.m` / `predict_ridge.m`: 两个预测器
- `solve_rebalance_lp.m`: column-major LP, 调 `linprog`
- `greedy_rebalance.m`、`evaluate_dispatch.m`
- `monte_carlo_robustness.m`、`export_figure_data.m`
- `tests/test_*.m`: 3 个手算验证的小算例 + `run_all_tests.m`

G Python 预处理与渲图说明

`code/python/` 8 个脚本, `venv (.venv/)` 隔离依赖:

- `01..04_*`: 下载 / 清洗 / 特征 / cost 矩阵
- `05_optional_maps.py`: 可选地图 (需 Shapefile)
- `06_validate.py`: 数据完整性 11 项断言
- `07_render_figures.py`: 仅做图像渲染, 不做任何数值计算
- `08_build_pptx.py`: 自动把 Beamer PNG + 讲稿同步进 `ppt/lecture.pptx`

H 蒙特卡洛参数

默认 $M = 200$ 次场景, 扰动方式取 Poisson (也支持残差 bootstrap)。随机种子固定为 20260521 保证可复现。对每个场景三种策略 共用固定调度矩阵 X^* (不重新求解), 避免“事后知道需求”的理想化偏差。

I λ 敏感性完整表

λ (mi)	mean unmet	mean cost (mi)	mean srv
1.000000	1027.777778	146.680694	0.700895
2.000000	973.041667	296.924653	0.709605
4.000000	965.083333	344.060417	0.711092
6.000000	964.504630	344.060417	0.711198
8.000000	957.060185	408.173380	0.712802
10.000000	912.523148	937.555764	0.727274
12.000000	909.444444	986.241134	0.727799
14.000000	909.824074	992.211713	0.727980
16.000000	909.092593	992.211713	0.728111
18.000000	853.467593	2552.490556	0.750732
20.000000	852.537037	2596.564884	0.750885
22.000000	852.365741	2596.564884	0.750918
25.000000	851.634259	2596.564884	0.751050
30.000000	851.634259	2596.564884	0.751050
40.000000	851.634259	2596.564884	0.751050
50.000000	851.634259	2596.564884	0.751050
75.000000	851.634259	2596.564884	0.751050
100.000000	851.634259	2596.564884	0.751050
150.000000	851.634259	2596.564884	0.751050
200.000000	851.634259	2596.564884	0.751050

参考基准（恒定）：greedy mean unmet = 845.0, greedy mean cost = 3053.3 mi。 $\lambda \leq 5$ LP 几乎不调度； $\lambda \in [10, 20]$ 转折区； $\lambda \geq 22$ 已完全饱和到同一最优解。

J AI 工具使用说明

完整说明见 docs/ai_usage.md。本项目的数学建模、北太天元代码、清洗阈值、 λ 经济推导与实验解读均由三人讨论完成；AI 工具仅在 Python / LaTeX 脚手架与样板格式上做过辅助，所有产出均经过单元测试、scipy 镜像或人工对算验证。

K 北太天元使用问题与建议

完整说明见 docs/beita_usage_notes.md。Baltamatica 2025 社区版六项兼容性发现：

- 无 figure/plot/print/close（已迁 Python matplotlib）
- csvread 在尾换行 + 多行时丢行且数值错乱（已改 fopen+fread+sscanf）
- error(...) 不接受 printf 多参数（已统一 error(sprintf(...))）
- onCleanup 不可用（已用 try/catch + 手动 fclose）
- containers.Map 不可用（已改 dense 3D 数组索引）
- 测试脚本 clear 清掉外层计数器（已去除）

L 成员分工

完整分工见 docs/division_of_labor.md。第一组按 **Modeling / Data / Presentation** 三个 lead 分工，工作量大致均衡：

- **22 光华王溪斌 (Modeling Lead)**: LP、Ridge、historical mean、evaluate_dispatch、 λ 经济推导、11 个 .m + 3 个 LP 单元测试、报告 §1 · §3 · §4 · §6 + 附录 D / E / I / K、Makefile；不录视频。
- **23 信科陈龙 (Data Lead)**: Python 7 个数据脚本（下载 / 清洗 / 特征 / cost 矩阵 / 校验）、06_validate.py 11 项断言、Monte Carlo 实验设计与 monte_carlo_robustness.m、报告 §2 · §5 + 附录 A / B / G / H、Beamer P1–P8 录音（8 帧约 11.5 min）。
- **23 元培汤平之 (Presentation Lead)**: 渲 6 张 PNG（07_render_figures.py）、自动 PPTX 拼装（08_build_pptx.py）、北太图源导出（export_figure_data.m）；报告与 Beamer 排版（含 ctex 调试）、报告 §5 解读、附录 C / F / J / L / M；4 个 docs markdown 文档；Beamer P9–P15 录音（7 帧约 9.5 min）、PowerPoint 合成与 MP4 导出。

M 复现说明

- `make data`: 下载、清洗、特征、cost 矩阵、11 项数据校验
- `make experiment`: 北太天元 LP 流水线 + Python 渲图
- `make report / make slides / make pptx`: 编译报告 / Beamer / 自动生成讲者备注 PPTX

详细步骤、协作者数据导入、期望数值对照表见 docs/reproduce.md。

N 完整图表合集




图 2: λ 敏感性曲线: λ 增大使 LP 多调度, unmet 下降, cost 上升; $\lambda \in [20, 200]$ 已饱和。

Monte Carlo robustness on last test hour




图 3: Monte Carlo 200 次 Poisson 扰动下三种策略的 unmet 与 service rate 分布。





图 4: Top-15 LP 调度流量 (24 测试小时累计)，前 5 条全部是 Manhattan 住宅区 → 机场。



(a) 周一至周日 × 24 小时平均 pickup (训练期)。

(b) 某高峰小时的供需缺口分布。

图 5: 时空模式可视化。